

Synthetic Data Generation Prompts

Synthetic Transcript Generation:

The synthetic transcript generation follows a word-count-based approach that replicates the empirical distribution of the Common Voice training set on both Dutch and Portuguese. The system generates sentences in batches of 25, targeting specific word counts to match the original dataset's statistical properties.

Generation Process

1. Word Count Distribution Analysis: Extract word count histogram from Common Voice training data for both languages.
2. Bucket-based Generation: Process each word count (1-30+ words) sequentially until quota is met.
3. Quality Filtering: Validate exact word count, remove duplicates, ensure proper formatting
4. Dynamic Correction: Provide specific feedback when generation errors occur
5. Token Frequency Control: Ban overused words to maintain lexical diversity

Dutch Language

System Prompt:

“Je bent een professionele schrijver van het Nederlands. Schrijf onafhankelijke, natuurlijke zinnen die geschikt zijn om hardop voor te lezen. Gebruik alledaags Nederlands vocabulaire en vermijd eigennamen of merknamen.”

Main generation Prompt:

*“TAAK: Genereer exact {N} onafhankelijke zinnen, elk met EXACT {W} woorden.
VERPLICHTE REGELS: . Elke zin moet exact {W} woorden hebben (tel zorgvuldig).
Volledige zinnen met eindinterpunctie (. ? !). Natuurlijke inhoud voor hardop lezen.
Alledaags Nederlands vocabulaire (vermijd merken/eigennamen). Geen aanhalingstekens of speciale opmaak. Variatie in onderwerpen: dagelijks leven, weer, familie, werk, hobby's.
Gebruik Nederlandse taalstructuren en idiom. Antwoord: pure JSON array van strings
VOORBEELD van correct formaat voor {W} woorden: {example_format} Antwoord ALLEEN met de JSON array:”*

Error Correction Prompt:

“CORRECTIE NODIG - Genereer opnieuw {batch_size} zinnen met exact {word_count} woorden: {error_count} zinnen hadden een verkeerd aantal woorden Voorbeeld: '{example}...' = {actual_wc} woorden (moet {target_wc} zijn) . VEREISTEN: • Exact

{word_count} woorden per zin • JSON array formaat • Geen duplicaten • Correcte Nederlandse interpunctie • Natuurlijke, voorleesbare zinnen • Alledaags Nederlands vocabulaire

Token Frequency Control

When certain words become overused, the system adds a ban block: *“Vermijd deze veelgebruikte woorden: [“de”, “het”, “een”, “is”, “van”, ...]”*

Portuguese Language.

The generation process follows the same procedures as for the Dutch language, however with prompts in Portuguese.

System Prompt:

“Você é um redator profissional de português brasileiro. Escreva frases independentes, naturais, adequadas para leitura em voz alta.”

Main generation Prompt:

“TAREFA: Gere exatamente {N} frases independentes, cada uma com EXATAMENTE {W} palavras. REGRAS OBRIGATÓRIAS: Cada frase deve ter exatamente {W} palavras (conte cuidadosamente). Frases completas com pontuação final (. ? !). Conteúdo natural para leitura em voz alta. Vocabulário cotidiano (evite marcas/nomes próprios). Sem aspas ou formatação especial. Resposta: array JSON puro de strings EXEMPLO de formato correto para {W} palavras: {example_format} Responda APENAS com o array JSON:”

Error Correction Prompt:

“CORREÇÃO NECESSÁRIA - Gere novamente {batch_size} frases de exatamente {word_count} palavras: {error_count} frases tinham contagem incorreta de palavras Exemplo: '{example}...' = {actual_wc} palavras (deve ser {word_count}). REQUISITOS: Exatamente {word_count} palavras cada | JSON array | Sem duplicatas | Pontuação final”

Token Frequency Control

The prompt for words that become overused: *“Nao use : [“o”, “de”, “e”, “a”, “que”, “do”, “da”, ...]”*.